

Proximal Policy Optimization Algorithms

20201622 이시욱

GitHub link :

프로젝트 주제 및 목표

주제


Classic Control 환경(CartPole-v1)에서 기본 reinforce(정책 경사 기본 알고리즘)와 PPO-Clip(안정화 정책 경사)의 성능 차이를 검증

목표

- CartPole-v1에서의 reinforcement와 PPO의 성능 비교
- clip epsilon 변경 후 안정성 및 성능 변화 분석

실험 환경 및 데이터 processing

- CartPole-v1 : 카트를 조종하여 막대기가 넘어지지 않도록 하는 실험 환경
- 카트를 움직이는 환경과의 상호작용에서 생긴 trajectory를 생성하여 제공하는 연속값 벡터 그대로 사용



State & Action & Reward

State

- 카트 위치
- 카트 속도
- Pole 각도
- Pole 각속도

Action

- 카트 왼쪽 밀기
- 카트 오른쪽 밀기

Reward

Timstep이 지날 수록 생존 reward +1

최종 Episode
reutrun : 버틴 시간

알고리즘 & Hyperparameter : Baseline

Reinforce(Baseline)

- 몬테 카를로 Policy 채용
- Episode 종료 후 $\log \pi(a|s)$ 및 $return$ 으로 policy update

Hyperparameter

gamma : 0.99

lr : 1e-3

Hidden : 128 layer

Total_episode : 600

알고리즘 & Hyperparameter : Main

PPO-Clip(Main)

- GAE 기반 advantage 이용
- Policy의 변화를 clipping으로 제한

Hyperparameter

Total step : 100,000	rollout_len : 1024	update_epochs : 5
Minibatch : 5	gamma = 0.99	gae_lambda = 0.95
lr : 3e-4	vf_coef : 0.5	ent_coef = 0.0
Clip_eps : 0.1 & 0.2 try		

실험 환경 및 Setup

실험환경

- CartPole-v1 및 RTX 4070 이용
- seed 3개(0,1,2)를 반복 후 평균과 표준편차 구함

평가 지표


- Baseline : 마지막 100 episode의 평균
- Main : 50 episode의 평균

실험 결과

	Seed 0	Seed 1	Seed 2	평균	표준편차
Reinforce	33.10	33.64	39.65	35.46	2.97
PPO_0.1clip	297.98	290.26	364.22	317.49	40.66
PPO_0.2clip	212.20	282.08	292.54	262.27	43.68

< 각 try의 seed별 return 점수 및 평균과 표준편차 >

실험 결과



<episode 진행에 따른 각 try별 학습률 곡선>

토의 및 결론

Reinforce

단순한 구조이나 고분산되어 안정적인 성능 확보 어려움

PPO

GAE + value 학습과 clipping을 이용하여 policy update 안정화를 통해 학습률과 성능을 확보

결론

PPO 알고리즘을 통한 학습이 유의미한 성능적 우세를 보이며, 본 실험에서는 clip이 0.1일 때 유리한 성능을 보임을 확인

개선점 및 추가 실험 방향

Seed 수 늘리기

Seed수를 늘려 신뢰 구간을 국소화 해 높은 신뢰성 확보

다른 실험 환경에서의 적용

Acrobot과 MountainCar 등 본 실험의 CartPole-v1이 아닌 다른 환경에서도 적용되는지 확인